

Rapport de Présentation — Projet ETL M2

KODJO Messanh


Juin 2026

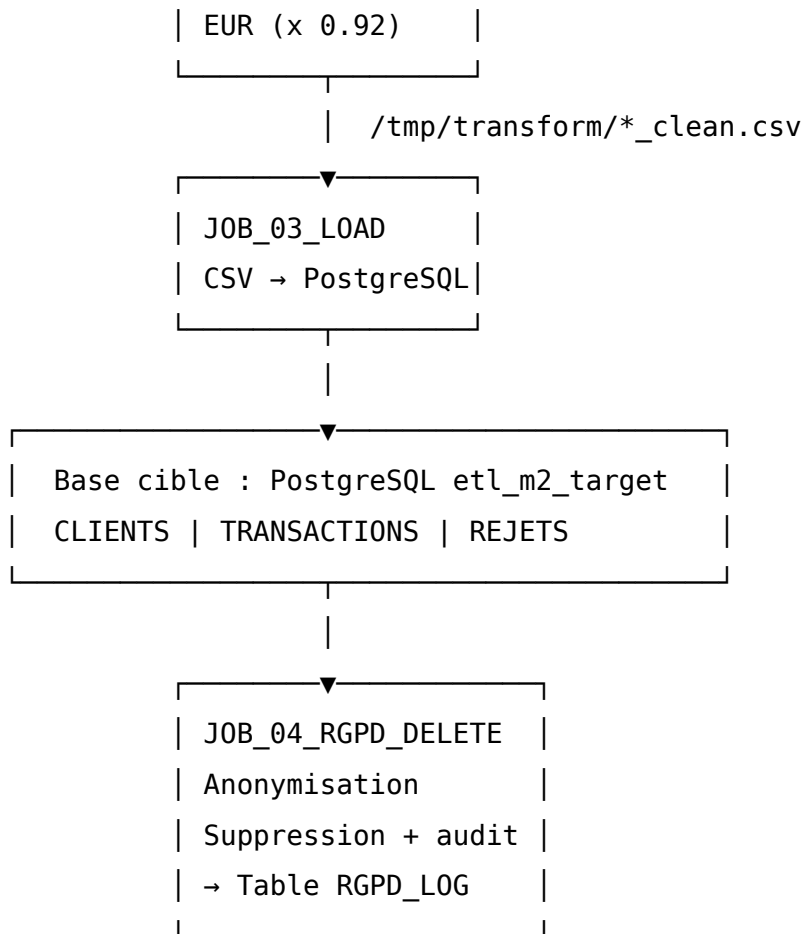
Présentation du projet

Ce projet a pour objectif de mettre en place un pipeline ETL complet permettant de migrer les données d'une base CRM source vers une base analytique cible, tout en assurant la conformité au RGPD. Le travail a été réalisé avec Talend Open Studio et s'appuie sur PostgreSQL comme système de base de données.

Le pipeline est structuré en quatre jobs distincts, chacun prenant en charge une étape précise du traitement. Un cinquième job, le MASTER_JOB, est prévu pour orchestrer leur exécution dans l'ordre.

Architecture du pipeline





Description des jobs

JOB_01_EXTRACT

Ce premier job se connecte à la base source `crm_source` et extrait les données des tables `clients` et `transactions` pour les sauvegarder en fichiers CSV dans `/tmp/extract/`. C'est le point d'entrée du pipeline, simple dans son rôle mais essentiel car tout ce qui suit en dépend.

JOB_02_TRANSFORM

C'est ici que les données sont nettoyées et mises en forme. On applique notamment la conversion des montants de USD vers EUR en utilisant le taux de change 0.92 défini dans le contexte. Les lignes invalides ou incomplètes sont isolées avant le chargement. Les fichiers produits, `clients_clean.csv` et `transactions_clean.csv`, sont déposés

dans /tmp/transform/.

JOB_03_LOAD

Ce job est le plus abouti du projet — c’est le seul entièrement compilé et prêt à l’exécution. Il lit les deux fichiers CSV nettoyés et les charge dans la base cible `etl_m2_target`. Les clients sont insérés dans la table `CLIENTS` (11 colonnes : identifiant, nom, prénom, email, téléphone, date de création, segment marketing, adresse, ville, code postal, pays). Les transactions vont dans la table `TRANSACTIONS`. Le chargement se fait par lots de 10 000 lignes pour des raisons de performance. Les enregistrements qui posent problème lors de l’insertion ne bloquent pas le traitement : ils sont redirigés vers une table `REJETS` avec le nom du job et les données sources concernées.

JOB_04_RGPD_DELETE

Ce job répond à l’exigence du droit à l’effacement prévu par le RGPD. À partir d’une liste de clients à traiter (identifiés par leur `customer_id` ou leur email), il effectue plusieurs opérations enchaînées : d’abord il anonymise les transactions liées en remplaçant le `customer_id` par la valeur `ANONYMIZED`, ensuite il supprime la ligne client dans la table `CLIENTS`, puis il enregistre l’action dans une table d’audit `RGPD_LOG`. Une vérification finale compte les transactions résiduelles pour s’assurer que l’anonymisation est complète.

Stack technique

Le projet repose sur Talend Open Studio 8.0.1 pour la conception et la génération du code Java. Le build est géré par Apache Maven, ce qui permet de packager chaque job de façon autonome avec ses dépendances. La base de données utilisée est PostgreSQL, accessible via le driver JDBC 42.2.14. La journalisation s’appuie sur Log4j 2.